

# Построяване на оптимални кодове

- Ефективност на кода и степен на компресия
- 2. Метод на Шенон-Фано.
- 3. Метод на Хафмън.
- 4. Предимства и недостатъци на побуквеното кодиране.
- 5. Класификация на методите за компресия.
- 6. Методи за компресия без загуби.
- 7. Методи за компресия със загуби.
- 8. Смесени методи за компресия.
- 9. Граници за компресия???

## 1. Ефективност на кода и степен на компресия

Ефективност на кода: Отношението на ентропията на източника Ікъм цената на кода Кза този източник **H(I)/L(K)**.

Очевидно 0&LTH(I)/L(K)<=1.

В компютърните компресиращи програми една по-практична оценка за тяхната ефективност е степента на компресия



### Степен на компресия

(1-L<sub>compressed</sub>/L<sub>uncompressed</sub>)\*100%

където L<sub>uncompressed</sub> и L<sub>compressed</sub> са съответно дължината на съобщението (например файл ) преди и след компресия.

Понякога вместо горната величина се дава просто отношението некомпресирана:компресирана дължина (Например: 10:1). Това е поудобно при големи степени на компресия - основно при компресия със загуби.

## 2. Метод на Шенон-Фано

Алгоритъмът на Шенон-Фано се базира на следното:

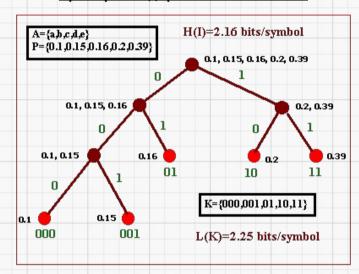
- За двубуквена азбука оптималния код е K={0,1} с цена L(K) = 1.
  Горната цена на кода ще бъде равна на ентропията на източника ( т.е. кодът ще има максимална ефективност ( т.е. кодът це има максима ефективност ( т.е. кодът це има ефективност ( т.е. кодът це има

$$\sum_{i=1}^{j} p_i \, u \sum_{i=j+1}^{n} p_i \, c$$
а максимално близки до 0.5, т.е. ако  $j$  е такова, че с

минимизира 
$$\left|\sum_{i=1}^{j}p_{i}-\sum_{i=j+1}^{n}p_{i}\right|$$

• Оптималният код за I<sub>1</sub> ще бъде максимално ефективен ако

## Пример за кодиране по Шенон-Фано



Методът на Шенон-Фано не гарантира получаването на оптимален код.

## 3. Метод на Хафмън

Методът на Хафмън позволява получаване на **оптимален** код за зададен източник. Той се базира на следните две теореми:



Ако I е n буквен източник с вероятности

$$p_1 >= p_2 >= ..p_j >= ..> = p_n$$

то съществува оптимален префиксен код с дължини на кодовите думи

като последните две кодови думи имат вида а0 и а1 (а е двоична поредица). Ако К е оптимален код с кодови думи {a<sub>1</sub>,a<sub>2</sub>,...a<sub>n</sub>} за **n** буквен източник с вероятности  $p_1 >= p_2 >= ..p_i >= ..>= p_n$ то кодът К' с кодови думи  $a_1, a_2, ... a_{i-1}, a_{i+1}, ..., a_i 0, a_i 1$ е оптимален за n+1 буквен източник с вероятности  $p_1 >= p_2 >= ... p_{i-1} >= , p_{i+1} >= ... >= p_n >= q >= s$ където q+s=p<sub>i</sub>. Пример за кодиране по Хафмън A={a,b,c,d,e} P={0.1,0.15,0.16,0.2,0.39} H(I)=2.16 bits/symbol 039 >0.61 0.39 0.39 0.20 0.25 0.16 0.20 0.15 0.10 0.16 1 000 001 010 011 K={011,010,001,000,1} L(K)=2.22 bits/symbol 4. Предимства и недостатъци на побуквеното кодиране. Предимства • Кодирането е без загуба на информация. Ако източника е известен, то съществува алгоритъм за построяване на оптимален за този източник код PDFmyURL.com (Хафмън).

Кодирането и декодирането са прости и бързи алгоритми, които лесно се реализират софтуерно и хардуерно.

#### • Недостатъци

Кодирането се базира на предварително зададен източник ( статичен модел). "Построяването" на източника точника точника

Пример Модел на английската азбука с фиксирани вероятности, използван като източник за а) литературен текст. b) текст на Pascal.

• Кодирането може да е далече от оптималното ако първичната азбука на източника е с малък брой букви.

Пример При предаване по факс. Азбука от две букви: {черно, бяло}. Цена на оптималния код е 1 бит/символ. Ентропия на източника е H=p log 2 p+(1-p) log 2 (1-p) <= 1

• Алгоритъма на Хафмън е за т.н. **модел от 0-лев порядък** (отчитат се само вероятностите на буквите на първичната азбука p<sub>i</sub>, но не и 'взаимните' вероятности p<sub>ii</sub>, p<sub>iik</sub> и т.н).

#### • Преодоляване на недостатъците

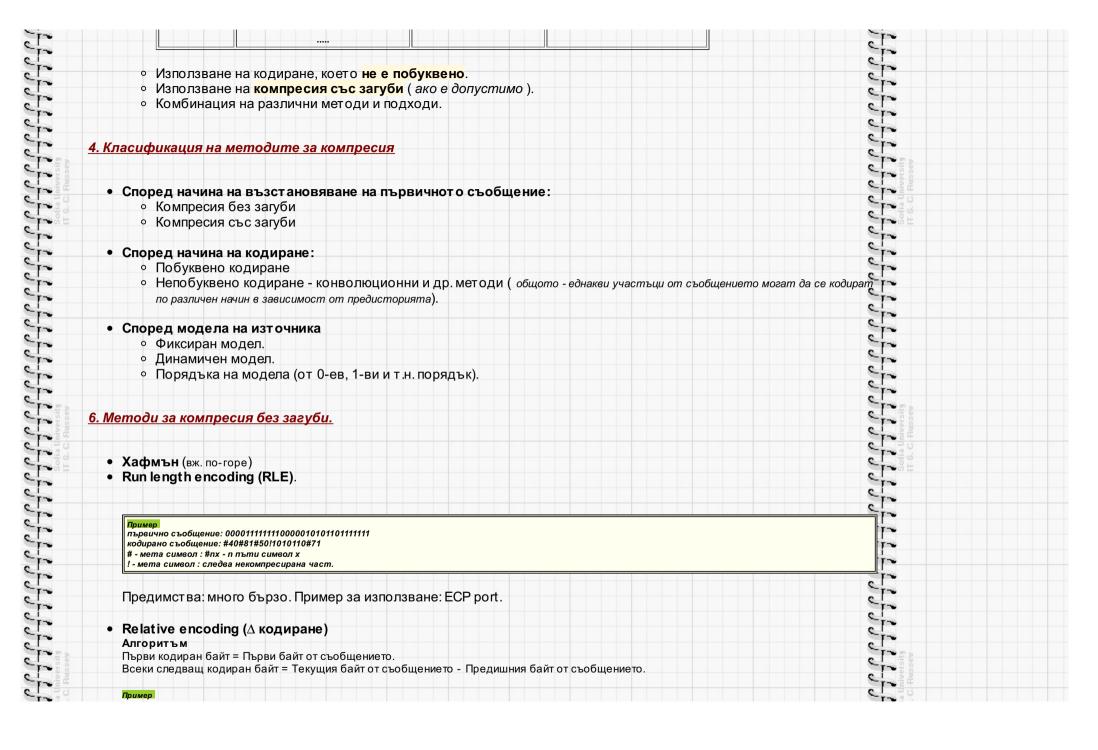
Използване на динамични модели.

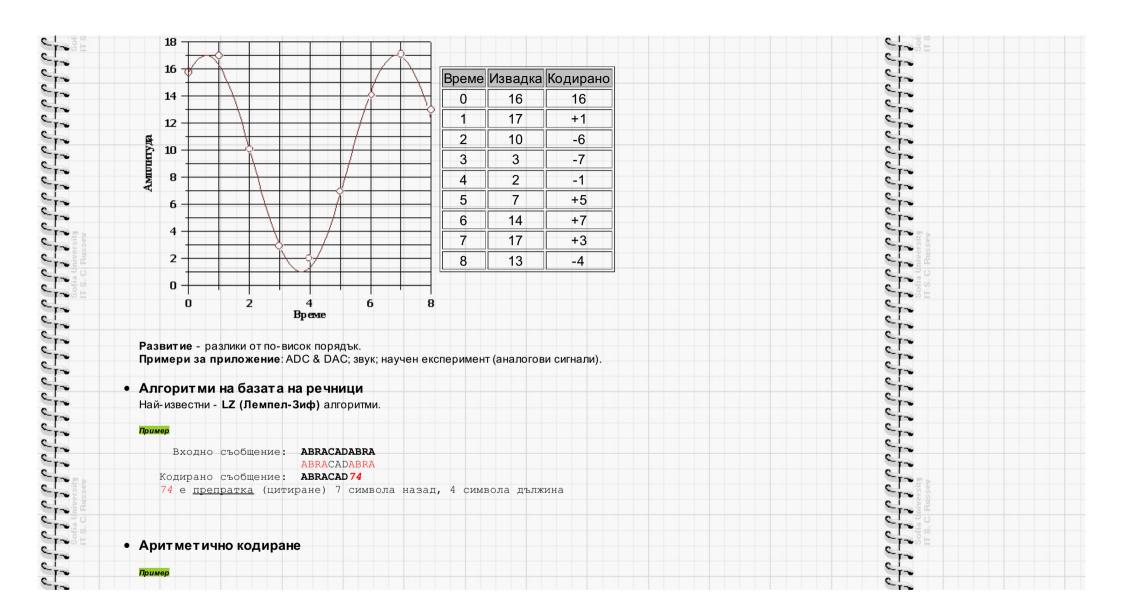
Пример Оценка на вероятностите от честотата на срещане на символите в самото съобщение. предават и вероятностите.

За достатъчно дълги съобщения. Недостатък: трябва да се

Използване на модели от по-висок порядък. Трудности: 1. Броят на отчитаните вероятностите расте много бързо. 2. с.
 Построяването на адекватен модел е трудно.

Пример Параметри на модели от различен порядък: **Брой вероят ност и** Пример за азбука с 30 букви Отчитани Порядък Брой вероятности на модела вероятности на буквите p=1/n-1 0  $p_{1}, p_{2}..p_{n}$ 30 n  $p_1, p_2..p_n$ p<sub>11</sub>, p<sub>21</sub>..p<sub>n1</sub> n+n<sup>2</sup> 930 p<sub>12</sub>, p<sub>22</sub>..p<sub>n2</sub> p<sub>1n</sub>, p<sub>2n</sub>..p<sub>nn</sub>  $p_{1}, p_{2}..p_{n}$ p<sub>11</sub>, p<sub>21</sub>..p<sub>n1</sub> p<sub>12</sub>, p<sub>22</sub>..p<sub>n2</sub>  $n+n^2+n^3$ 27930  $p_{1n}, p_{2n}..p_{nn}$ p<sub>111</sub>, p<sub>121</sub>..p<sub>1n1</sub>





C	
C	<u></u>
C	1-
C	1
C	1
C	1-
000	
C	12
C	77777777777
C	77777
C	12
C	1-
C	1-
c_	T~
C	1~
C	1~
C	T~
C	1-
C	777777
C	-
C	T~
C	T~
0000000000	77777
-	1-
C	T
C	T
C	77777777777777
C	T
C	T
C	T
C	T
C	1~
C	1~
C	1-
0000	
C	-
_	TT
C	1~
C	1~
C	-
C	-
C	-
C	-
C	-
C	-
C	-

Буква	Вероятност	Интервал	
Space	0.1	0.0 - 0.1	
A	0.1	0.1 - 0.2	
В	0.1	0.2 - 0.3	
E	0.1	0.3 - 0.4	
G	0.1	0.4 - 0.5	
Ĩ	0.1	0.5 - 0.6	
i	0.2	0.6 - 0.8	
S	0.1	0.8 - 0.9	
Ť	0.1	0.9 - 1.0	

#### Вероятности на буквите в свобщението BILL GATES

Следваща буква	Долна граница	Горна граница	
	0.0	1.0	
В	0.2	0.3	
i i	0.25 0.256	0.26 0.258	
- Ī	0.2572	0.2576	
Space	0.2572	0.25724	
Ģ	0.257216	0.257220	
A	0.2572164	0.2572168	
F	0.25721676 0.257216772	0.2572168 0.257216776	
S	0.2572167752	0.2572167756	

#### Кодиране на съобщението BILL GATES

Чнело	Буква	Граннци		Интервал
0.2572167752 0.572167752 0.72167752	B I L	0.2 0.5 0.6	0.3 0.6 0.8	0.1 0.1 0.2
0.6083876 0.041938 0.41938 0.1938	Space G A	0.6 0.0 0.4 0.2	0.8 0.1 0.5 0.3	0.2 0.1 0.1 0.1
0.938 0.38 0.8 0.0	T E S	0.9 0.3 0.8	1.0 0.4 0.9	0.1 0.1 0.1

Декодиране на свобщението BILL GATES

• Математически трансформации - Фурие и др.

# 7. Методи за компресия със загуби.

Къде е допустимо?: Информация, свързана с човешки възприятия (5-те сетива).

Пример Звук: 20 Hz - 20 kHz, но най-голяма чувствителност в средната честотна област и <u>нормален</u> интензитет.

Методи:

